

MTMS.01.088 Mitmemõõtmeline analüüs
Faktoranalüüs
Projekt

Anti Ingel

15. aprill 2016. a.

1 Sissejuhatus

Töö eesmärgiks on proovida faktoranalüüsi kasutades täiendada autori varasemat tööd, milleks on visuaalselt esilekutsutud potentsiaalidel (VEP) põhinev aju-arvuti liides (AAL). AALiks nimetatakse aju ning arvuti vahelist otsest suhtluskanalit ehk tavaliselt arvuti-programmi, mis saab sisendi kasutaja ajast. Seega kasutaja ei pea arvutiga suhtlemiseks vajutama nuppudele, vaid ajus esile kutsuma teatud signaali, mida on võimalik aju tegevuse salvestamiseks mõeldud seadmetega mõõta ning salvestusest tuvastada.

Kasutaja ajutegevuse mõõtmiseks kasutatakse tavaliselt elektroentsefalograafiat (EEG), kuna võrreldes teiste meetoditega on EEG muutunud väga odavaks ning viimasel ajal on lisaks professionaalsetele seadmetele välja tulnud ka tarbijatele orienteeritud kasutajasõbralikke seadmeid.

Et EEG salvestuse põhjal otsustada, millist käsku kasutaja arvutile edastada soovib, tuleb salvestusest eraldada tunnused. VEPil põhinevad AALid jagunevad omakorda erinevat tüüpi AALideks vastavalt sellele, kuidas VEP ajus esile kutsutakse ning seejärel EEG salvestusest tuvastatakse. Üks populaarsemaid viise on kasutada sagedusel põhinevaid VEPe, mille puhul on EEG signaalist eraldatavateks tunnusteks kindlad sagedused. Igale käsule, mida kasutaja saab arvutile edastada vastab kindel sagedus. Sagedus kutsutakse ajus esile visuaalse stiimuliga, mida näidatakse kasutajale arvuti ekraanil.

Antud AAL põhinebki sagedustel ning kasutab elektroentsefalogrammist tunnuste eraldamiseks kahte erinevat meetodit—võimsusspektri analüüsi ning kanoonilist korrelatsioonanalüüsi. Kanoonilise korrelatsioonanalüüsi meetod arvutab igale käsu sagedusele vastava kanoonilise korrelatsiooni EEG signaaliga. Võimsusspektri analüüsi meetodiga saab aga kindlaks teha kui palju käsule vastavat sagedust EEG signaalis on.

Lõpuks tuleb saadud tunnuste põhjal otsustada, millist käsku soovis kasutaja arvutile edastada. Ilmselt mida suurem on kanooniline korrelatsioon vastava käsu sagedusel EEG signaaliga ning mida rohkem vastava käsu sagedust EEG signaalis on, seda suurema tõenäosusega soovis kasutaja just seda käsku edastada. Aga kuna meetodeid on mitu ja kumbki meetod eraldab tunnuseid iga käsu kohta, siis tulemuseks on hulk tunnuseid, mida on raske interpreteerida.

Kuna varasemalt taolist erinevate tunnuste eraldamise kombineerimist tehtud ei ole, siis olemasolevast kirjandusest on vähe abi ning siit tekibki küsimus—kuidas kõigi nende saadud tunnuste põhjal teha lõplik otsus, millist käsku kasutaja soovis edastada? Kas mõlemal meetodil peaks olema võrdne kaal lõpliku otsuse tegemisel või ühel neist suurem? Kui palju peaks suurim korrelatsioon/võimsus olema teistest parem?

Taoliste küsimuste jaoks vastuse saamiseks proovingi kasutada faktoranalüüsi, et esitada eraldatud tunnused vähemate tunnuste kaudu ning seeläbi lihtsustada kasutaja edastatud käsu kindlaks tegemist.

2 Andmete kirjeldus

Kuna töö eesmärgiks on autori enda kirjutatud AALi täiendamine, siis ka andmed on autori enda kogutud. Andmed ise ning näited andmete kohta on lisas B.

2.1 Elektroentsefalogramm

EEG signaali mõõtmiseks kasutati Emotiv EPOC seadet, mille mõõtmisagedus on 128 Hz ning 14 võimalikust sensorist kasutati ainult nelja sensorit, mille asukohad on 10-20 elektroodide paigutamise süsteemi järgi P7, O1, O2 ja P8. Need sensorid valiti, kuna asuvad nägemiskeskusele kõige lähemal ja seega on parimad VEPide tuvastamiseks. Täielikud EEG seadme spetsifikatsioonid on Emotivi kodulehel¹.

EEG signaal AALi kasutamise ajal salvestati viielt tervelt inimeselt, kellel varasem AALi kasutamise kogemus puudus. Edasises analüüsis kasutatakse ainult ühe inimese EEG signaali, kuna erinevate inimeste EEG signaal erineb. Üks signaal valiti välja selle põhjal, millel kõige selgemalt alfa-lained ülejäänud signaalist eristusid.

EEG signaali andmestikus on tunnusteks EEG sensorite asukohad 10-20 elektroodide paigutamise süsteemi järgi ning vaatlusteks on vastava sensori mõõdetud pinge erinevus tugisensori mõõdetud pingest mikrovoltides iga $\frac{1}{128}$ sekundi järel, mille sisse on arvestatud ka $4000\mu V$ nihe.

2.2 Visuaalselt esilekutsutud potentsiaalid

VEPide esilekutsumiseks, st kasutajale visuaalsete stiimulite näitamiseks kasutati 14-tollist 60 Hz sagedusega 1600x900 resolutsiooniga monitori. Täielikud monitori spetsifikatsioonid on HP kodulehel².

EEG salvestamise ajal sai kasutaja edastada arvutile kolme erinevat käsku, nendele vastavad sagedused olid 6.67 Hz, 7.5 Hz ning 8.57 Hz. Käskude edastamise järjestus, mida kasutaja pidi järgima, oli arvuti poolt juhuslikult genereeritud ning kasutajale eksperimendi jooksul käsk-käsu haaval ekraanil näidatud. Seega kasutaja proovis edastada käske kindlas järjestuses ning edastatav käsk vahetus kindla aja möödudes. Seega on teada mis aja hetkel millist käsku kasutaja arvutile edastada proovis.

2.3 Eraldatud tunnused

EEG signaalist on omakorda eraldatud tunnused. Kanoonilise korrelatsioonimeetodiga on iga käsu jaoks iga $\frac{1}{128}$ sekundi järel arvutatud käsu sageduse ja EEG signaali vaheline kanooniline korrelatsioon. Võimsusspektri analüüsi meetodiga on iga käsu jaoks iga $\frac{1}{128}$

¹<https://emotiv.com/product-specs/Emotiv%20EPOC%20Specifications%202014.pdf>

²http://h71016.www7.hp.com/dstore/html/pdfs/AMS_HP_EliteBook_840_G1_Notebook_PC_Data_Sheet.pdf

sekundi järel arvutatud käsule vastava sageduse hulk EEG signaalis tugisensori signaali suhtes, ühikuks on $\left(\frac{\mu V^2}{Hz}\right)$. Lisaks käsu enda sagedusele, arvutab võimsusspektri analüüsi meetod ka tunnuse iga käsu sageduse teise harmooniku jaoks, kuna teise harmooniku hulk signaalis see aitab kasutaja käsku kindlaks teha.


Andmestikus kasutatavad lühendid

- CCA - kanooniline korrelatsioonanalüüs
- PSDA - võimsusspektri analüüs
- f1 - sagedus 1
- h1 - sageduse esimene harmoonik (ainult võimsusspektri analüüsi puhul)
- sum - tulemus summeeritud üle harmoonikute (ainult võimsusspektri analüüsi puhul).

Näiteks tunnuse CCA_f1 väärtus 0.8 tähendab, et vaadeldaval ajahetkel oli EEG signaali ja 1. käsu sagedusega (6.67 Hz) sinusoidi kanooniline korrelatsioon 0.8. Käsu kindlaks tegemiseks võib näiteks võrrelda tunnuste CCA_f1, CCA_f2 ja CCA_f3 väärtuseid ja valida nende hulgas suurima väärtusega tunnus.

Näiteks tunnuse PSDA_h2_f3 väärtus näitab aga kui palju 3. käsu sageduse (8.57 Hz) teist harmoonikut ($8.57 \cdot 2 = 17.14$ Hz) vaadeldaval ajahetkel signaalis on. Jällegi võib võrrelda kõiki antud meetodi tunnuste väärtuseid iga käsu kohta, st tunnuste PSDA_h2_f1, PSDA_h2_f2, PSDA_h2_f3 väärtuseid ning valida nende hulgas suurim, et kindlaks teha, millist käsku kasutaja selle meetodi arvates edastada tahtis.

Tahame aga mõlemad meetodid koos tööle panna ja üks võimalus seda teha on omistada igale tunnusele oma kaal, kui palju antud tunnus lõplikku otsust mõjutab. Selleks proovimegi kasutada faktoranalüüsi.



Joonis 2.1: Esialgne EEG signaal

3 Faktoranalüüs

Kuna EEG signaalist eraldatud tunnuste puhul on tegemist aegreaga, siis vaatlused andmestikus ei ole sõltumatud. Seega tavalise faktoranalüüsi puhul ei saa me teha järeldusi väljaspoole antud andmestikku. Siin aga tuleb appi aegride faktoranalüüs, mis ei tee vaatluste sõltumatuse eeldust, ning mida hiljem antud töös rakendatakse. Küll aga saame tavalist faktoranalüüsi kasutada antud andmestiku kokku surumiseks.

Lisaks prooviti töö käigus rakendada ka dünaamilist faktoranalüüsi, mis sobib samuti aegride faktoranalüüsi tegemiseks, aga erinevalt aegride faktoranalüüsist oli meetodi rakendamine ilma taustateadmisteta keerukas ning seetõttu dünaamilise faktoranalüüsiga tulemusteni antud töös ei jõutud.

Faktoranalüüsi prooviti rakendada ka EEG signaalile, aga nagu joonisel 2.1 näha, on erinevatest sensoritest saadud signaalid omavahel tugevalt korreleeritud ning seega saadakse tulemuseks üks faktor, mis on tugevalt seotud kõigi sensorite signaalidega. Seega EEG signaalile rakendatud faktoranalüüs (vähemasti antud sensorite korral) antud töös püstitatud küsimustele vastust leida ei aita.

Järgnevalt läheme EEG signaalist eraldatud tunnuste faktoranalüüsi juurde.

3.1 Tunnuste ja faktorite arv

Edasiseks analüüsiks valiti 6 tunnust (CCA_f1, CCA_f2, CCA_f3 ning PSDA_sum_f1, PSDA_sum_f2, PSDA_sum_f2), iga käsu kohta kanoonilise korrelatsioonanalüüsi tulemus ja iga käsu kohta võimsusspektri analüüsi üks tulemus. Kui kasutada mitut võimsusspektri analüüsi tunnust iga käsu kohta, siis kipub faktoranalüüs ära kirjeldama just võimsusspektri analüüsi meetodid ning seejuures jätab kanoonilise korrelatsioonanalüüsi meetodi praktiliselt kirjeldamata. Seda me aga ei taha, kuna kanoonilise korrelatsioonanalüüsi meetod on käsu kindlaks tegemisel täpsem kui võimsusspektri analüüs.

Interpreteerimise huvides valiti faktorite arvuks kolm, kuna andmed on juhu kohta, kus kasutaja sai edastada kolme erinevat käsku. Sel juhul iga saadud faktor võiks vastata ühele käsule ning saame proovida kasutada kasutaja edastatud käsu kindlaks tegemiseks hoopis faktorite väärtuseid, mitte tunnuste omi. Vähemate või rohkemate tunnuste korral on interpreteerimine problemaatiline ning tõenäoliselt ei saa ka sel juhul faktorskoore käsu kindlaks tegemisel kasutada.

Nelja faktori korral tekkis üks faktor, mis on tugevalt seotud ainult kanoonilise korrelatsioonanalüüsi meetodiga. Selline faktor ei aita andmestikku kokku suruda, kuna otsime pigem meetodite vahelisi seoseid. Seega valimegi kolm faktorit.

Teine idee tunnuste ja faktorite arvu valimiseks oli, et valime tunnused, mis iseloomustavad ainult ühte käsku ehk näiteks käsu 1 puhul valime alamhulga tunnustest CCA_f1, PSFA_sum_f1, PSFA_h1_f1, PSFA_h2_f1 ning teeme faktoranalüüsi ühe faktori korral. Sellisel juhul on faktoranalüüs sunnitud just ühe käsu tunnused omavahel kombineerima ning ei saa tekkida mitte-interpreteeritavust erinevate käskude tunnuste kombineerimise tõttu. Antud idee ei mahtunud kahjuks antud töö skoopi.

Eigenvalues of the Correlation Matrix: Total = 6 Average = 1				
	Eigenvalue	Difference	Proportion	Cumulative
1	1.71478248	0.45281816	0.2858	0.2858
2	1.26196432	0.14222633	0.2103	0.4961
3	1.11973798	0.41156600	0.1866	0.6827
4	0.70817198	0.09523153	0.1180	0.8008
5	0.61294045	0.03053767	0.1022	0.9029
6	0.58240279		0.0971	1.0000

Joonis 3.1: Korrelatsioonimaatriksi omaväärtused. Näiteks omaväärtused >1 tingimuse järgi saaksime ka siit 3 faktorit.

3.2 Faktorlahend

Faktorlahendi leidmiseks võrreldi nelja meetodit: peakomponentide meetod, peafaktorite meetod, iteratiivne peafaktorite meetod ning aegridade faktoranalüüs, mis põhines suurima tõepära meetodil. Leitud faktorkaalud ning kommunaliteedid on visualiseeritud joonisel 3.4 ning tabelina toodud lisas D. Jooniselt näeme, et peafaktorite meetodid annavad väga sarnaseid tulemusi. Ka peakomponentide meetod väga palju peafaktorite meetodist ei erine, kuid nagu oodatud, kirjeldab ära suurema tunnuste dispersioonist ning seega omapärad on väiksemad. Suurima tõepära meetod head tulemust ei andnud, iga faktor on seotud peamiselt ainult ühe tunnusega ja seega tunnuseid kokku ei suruta.

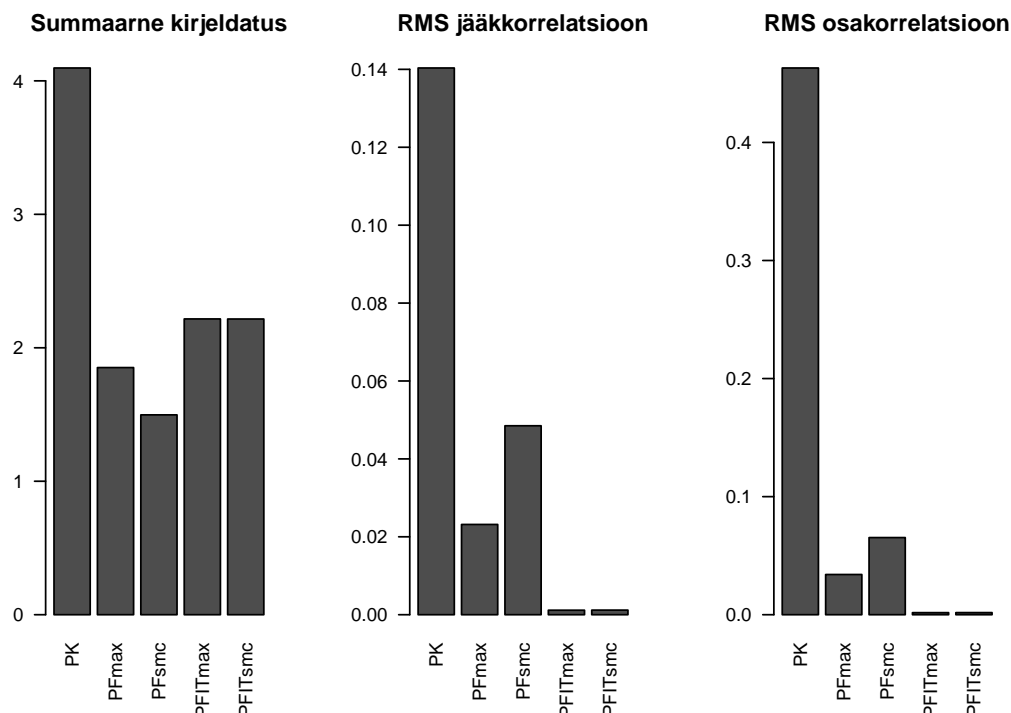
Teised headuse näitajad on toodud joonisel 3.3. Nagu näeme, on peafaktorite meetodi summaarne kirjeldatus hea ning ka teised näitajad on piisavalt väikesed. Peafaktorite meetod, nagu oodatud, on aga saavutanud väga väikesed jääkkorrelatsiooni ja osakorrelatsiooni maatriksi diagonaaliväliste elementide summad.

Kuna aga peafaktorite meetod kirjeldab suhteliselt halvasti tunnust CCA_f3 ja ka teiste tunnuste kommunaliteedid on üpris väikesed, siis valime lahendiks peakomponentide meetodi tulemuse.

Factor Pattern			
	Factor1	Factor2	Factor3
PSDA_sum_f1	0.68429	0.37492	-0.17477
PSDA_sum_f2	0.77374	-0.10748	0.05701
PSDA_sum_f3	0.63088	0.35200	0.39747
CCA_f1	-0.07868	0.71636	-0.48028
CCA_f2	0.45562	-0.64526	-0.12344
CCA_f3	-0.18989	0.23750	0.82587

Variance Explained by Each Factor		
Factor1	Factor2	Factor3
1.7147825	1.2619643	1.1197380

Joonis 3.2: Peakomponentide meetodil saadud faktorkaalud.



Joonis 3.3: Erinevate meetodite summaarne kirjeldatus, RMS jääkkorrelatsiooni maatriksi diagonaalivälistest elementidest, RMS osakorrelatsiooni maatriksi diagonaalivälistest elementidest.

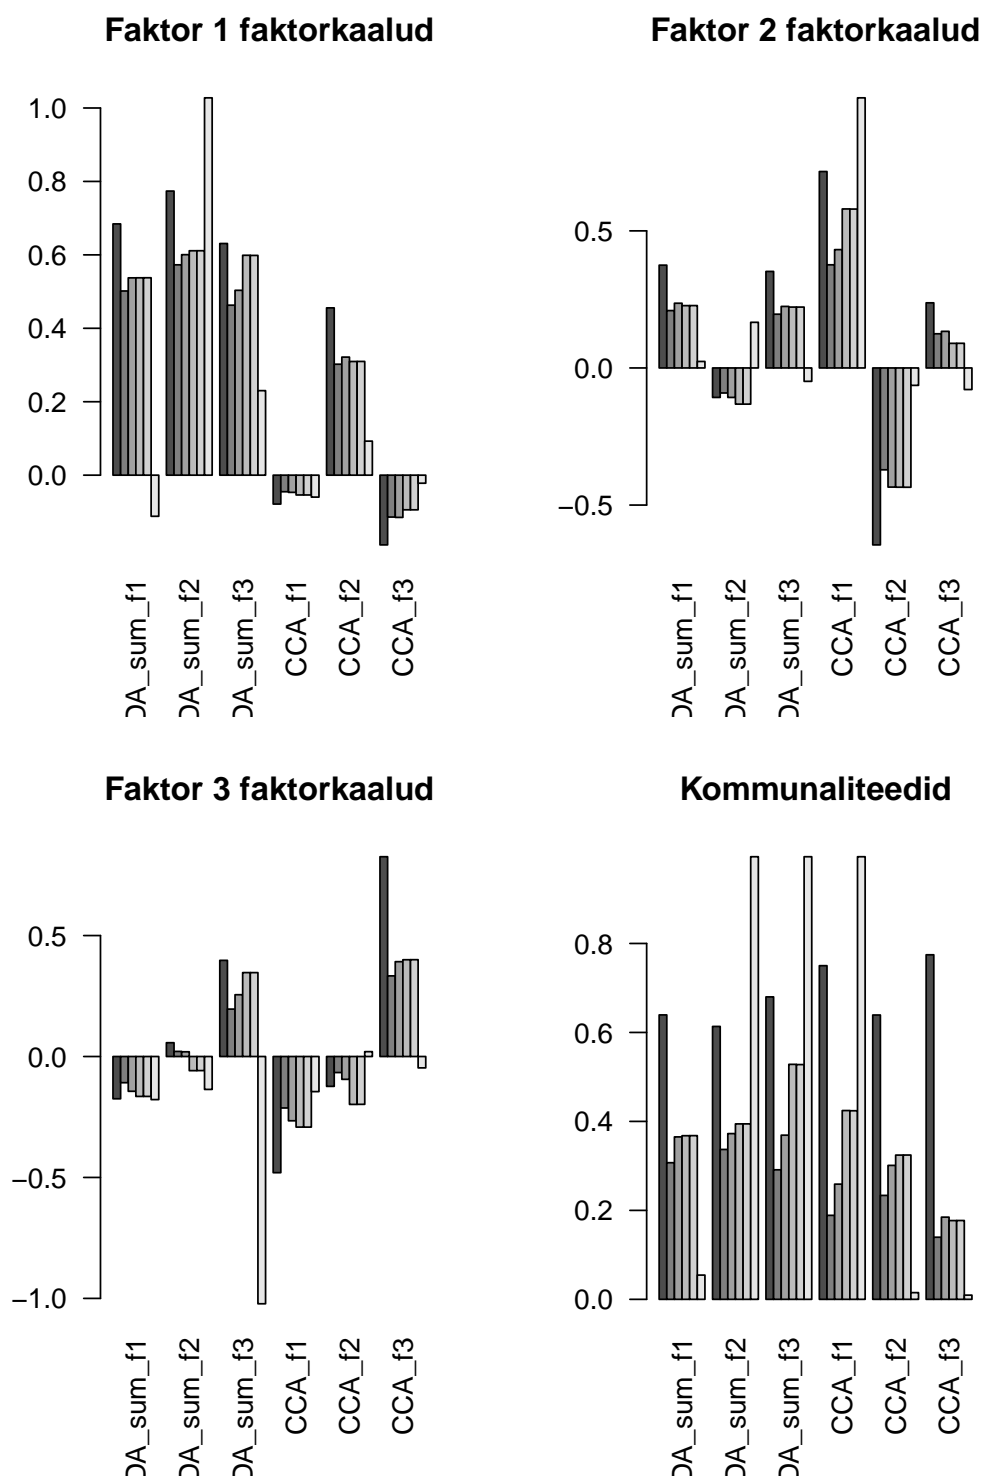
3.3 Pööramine

Et saavutada faktorstruktuur, mis vastab peatükis 3.1 seatud tingimusele, et iga faktor vastab ühele käsule, kasutame Prokrustese pööramist. Varimax ning teised tuntud meetodid ei andnud piisavalt hästi interpreteeritavat tulemust. Faktorite ning tunnuste korrelatsioonid on toodud joonisel 3.5. Näeme, et soovitud struktuur on päris hästi saavutatud. Esimesel faktoril on suured korrelatsioonid tunnustega PSDA_sum.f1 ja CCA.f1, teisel faktoril on suured korrelatsioonid tunnustega PSDA_sum.f2 ja CCA.f2 ning kolmandal tunnustega PSDA_sum.f3 ja CCA.f3.

Arvutame ka faktorite skoorid. Seda saame teha korrutades tunnuste vektori faktorskooride maatriksiga, aga SAS arvutab need ka automaatselt. Tulemus on toodud joonisel 3.6. Kuna aga antud jooniselt on raske midagi välja lugeda, siis järgnevalt proovime saadud faktorskooride põhjal ka kasutaja edastatud käsku kindlaks teha, et näha, kas antud tunnuste kokku surumisest oli ka kasu.

3.4 Faktorskooride põhjal klassifitseerimine

Järgnevalt proovime arvutatud faktorskooride põhjal kasutaja edastatud käsku kindlaks teha. Selleks kasutame kõige lihtsamat klassifitseerijat, mis teeb valiku lävendi põhjal. Kui faktorskoor on suurem kui lävend, siis ennustame, et kasutaja proovis faktorile vastavat käsku edastada. Kui lävend on väiksem, siis kasutaja ei proovinud antud käsku edastada.



Joonis 3.4: Faktorkaalud ja kommunaliteedid. Meetodid on kodeeritud toonidena tume-damalt toonilt heledamale (vasakult paremale) järgnevalt: peakomponendid, peafaktorid max, peafaktorid smc, iteratiivne peafaktor max, iteratiivne peafaktor smc, aegride faktoranalüüs suurima tõepära meetodil.


Antud meetod on väga ebatäpne, kuid siiski saame seda võrrelda esialgsete tunnuste põhjal klassifitseerimisega.

Factor Structure (Correlations)			
	Factor1	Factor2	Factor3
PSDA_sum_f1	0.72157	0.48229	0.27688
PSDA_sum_f2	0.32814	0.74830	0.31283
PSDA_sum_f3	0.42727	0.41801	0.71971
CCA_f1	0.67335	-0.33965	-0.14435
CCA_f2	-0.15173	0.68170	-0.17649
CCA_f3	-0.29523	-0.30484	0.70151

Variance Explained by Each Factor Ignoring Other Factors		
Factor1	Factor2	Factor3
1.3744878	1.6402851	1.2366020

Final Community Estimates: Total = 4.096485					
PSDA_sum_f1	PSDA_sum_f2	PSDA_sum_f3	CCA_f1	CCA_f2	CCA_f3
0.63936510	0.61347911	0.67989139	0.75003421	0.63918855	0.77452641

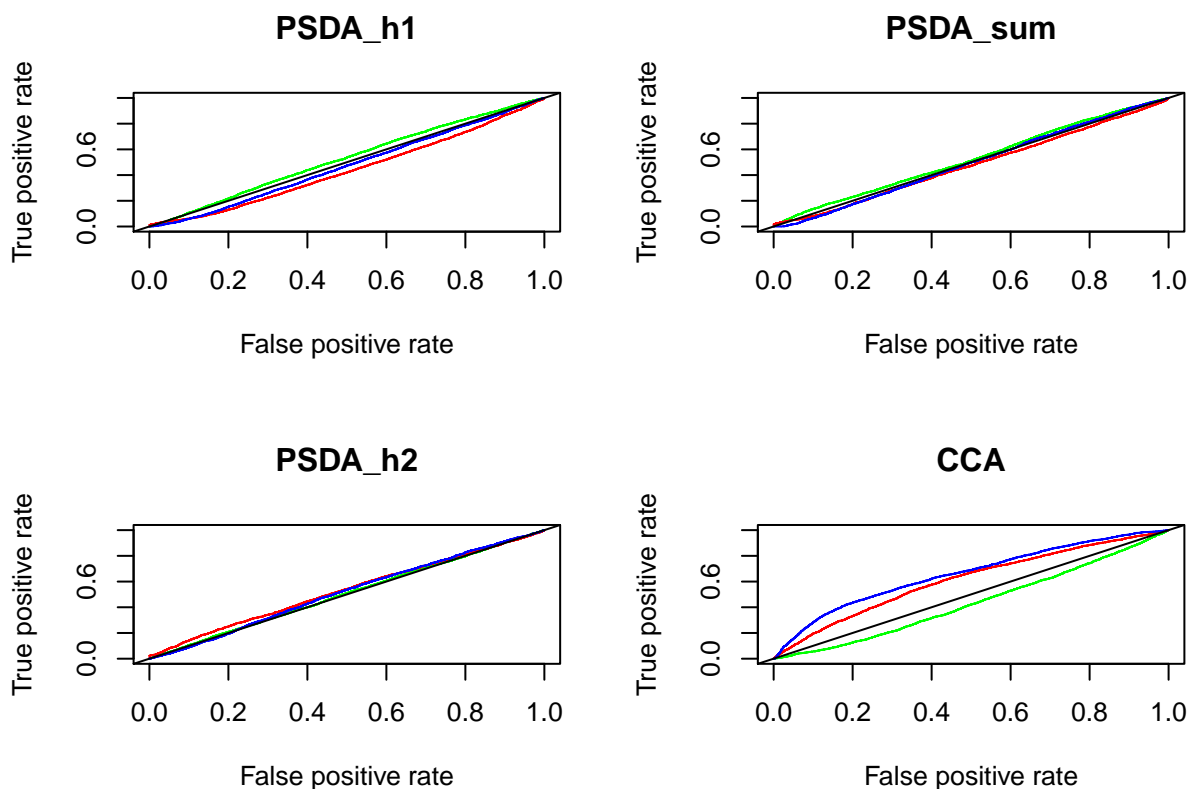
Joonis 3.5: Prokrustese pööramise tulemusel saadud faktorstruktuur.




Joonis 3.6: Faktorskoorid.

Binaarse klassifitseerija headust saab visualiseerida ROC kõveraga, millelt on näha kuidas sõltuvad klassifitseerija tundlikkus ja spetsiifilisus üksteisest. Mida kõrgemalt ROC kõver läheb, seda parem on klassifitseerija. Joonisel 3.7 näeme, et antud väga naiivne klassifitseerija eriti häid tulemusi ei anna. Kõige paremini töötab klassifitseerimine kanoonilise korrelatsioonanalüüsi tunnuste puhul.

Joonisel 3.8 on aga kujutatud faktorskooride põhjal klassifitseerimine. Näeme, et tulemus



Joonis 3.7: Esialgsete tunnuste põhjal klassifitseerimine. Roheline joon vastab käsule 1 (6.67 Hz), punane joon käsule 2 (7.5 Hz) ja sinine joon käsule 3 (8.57 Hz).



Joonis 3.8: Faktorskooride põhjal klassifitseerimine.

on parem kui ainult võimsusspektri meetodiga eraldatud tunnuste põhjal klassifitseerimine. Seega on lootust, et faktoranalüüsiga leitud faktorskooride põhjal klassifitseerimine töötab ka keerulisemate ja täpsemate klassifitseerijate korral.

4 Kokkuvõte

Antud töös kasutati faktoranalüüsi et suruda kokku EEG signaalist eraldatud tunnused, mille põhjal AAL proovib otsustada, millist käsku kasutaja arvutile edastada soovib. Tunnuste kokku surumine muudaks lihtsamaks käsu kindlaks tegemise, kuna vähemate tunnuste korral tuleb vähem manuaalselt otsida ja muuta parameetreid. Kui faktorlahendiks on nii paljude faktoritega struktuur kui palju on edastatavaid käske ning iga faktor on tugevalt seotud ühe käsuga (st vastava käsu jaoks eraldatud tunnustega), siis on võimalik faktorlahendit interpreteerida ning tõenäoliselt on võimalik ka faktorskoore kasutada klassifitseerimiseks.

Projekti edasi arendamise esimene samm oleks teha parem klassifitseerimise meetod ning vaadata, kuidas faktorskooride põhjal klassifitseerimine parema meetodi puhul töötab. Teiseks tuleks proovida peatükis 3.1 mainitud ideed kasutada ainult ühte faktorit ning ühe käsuga seotud tunnuseid.

Sain antud projekti käigus ideid oma AALi edasi arendamiseks ning loodetavasti viib mõni neist ka hea tulemuseni.

A SAS kood

Kogu kasutatud kood on kättesaadav koodirepositooriumist¹. Järgnevalt on aga toodud olulisemad koodi osad

```
data data; /* Andmete sisse lugemine */
infile 'test5_results_2_all.csv';
input ID PSDA_sum_f1 PSDA_sum_f2 PSDA_sum_f3
      PSDA_h1_f1 PSDA_h1_f2 PSDA_h1_f3
      PSDA_h2_f1 PSDA_h2_f2 PSDA_h2_f3
      CCA_f1 CCA_f2 CCA_f3;
run;

data TARGET; /* Pööramise soovitud tulemus */
Input _NAME_ $ PSDA_sum_f1 PSDA_sum_f2 PSDA_sum_f3
      CCA_f1 CCA_f2 CCA_f3;

list;cards;
FACTOR1 1 0 0 1 0 0
FACTOR2 0 1 0 0 1 0
FACTOR3 0 0 1 0 0 1
;
run;
/* Peakomponentide meetod pööramisega */
proc factor data=data method=prin priors=one rotate=procrustes
      target=target residuals nfactors=3;
var PSDA_sum_f1 PSDA_sum_f2 PSDA_sum_f3 CCA_f1 CCA_f2 CCA_f3;
run;
/* Peafaktorite meetod max */
proc factor data=data method=prin priors=max residuals nfactors=3;
var PSDA_sum_f1 PSDA_sum_f2 PSDA_sum_f3 CCA_f1 CCA_f2 CCA_f3;
run;
/* Peafaktorite meetod smc */
proc factor data=data method=prin priors=smc residuals nfactors=3;
var PSDA_sum_f1 PSDA_sum_f2 PSDA_sum_f3 CCA_f1 CCA_f2 CCA_f3;
run;
/* Iteratiivne peafaktorite meetod max */
proc factor data=data method=prinit priors=max residuals nfactors=3 maxiter=1000;
var PSDA_sum_f1 PSDA_sum_f2 PSDA_sum_f3 CCA_f1 CCA_f2 CCA_f3;
run;
/* Iteratiivne peafaktorite meetod smc */
proc factor data=data method=prinit priors=smc residuals nfactors=3 maxiter=1000;
var PSDA_sum_f1 PSDA_sum_f2 PSDA_sum_f3 CCA_f1 CCA_f2 CCA_f3;
run;
```

¹<https://github.com/kahvel/MAPProject>

B Andmestik

Kogu andmestik on kättesaadav koodirepositooriumist¹

Näide EEG signaali andmestiku kohta

O1	O2	P7	P8
9317	8587	9507	8518
9327	8604	9510	8526
9334	8613	9517	8519
9334	8611	9521	8531
9326	8598	9512	8529
9311	8580	9507	8506

Kasutatud käskude sagedused

ID	Frequency
1	6.666667
2	7.500000
3	8.571429

Näide EEG signaalist eraldatud tunnuste kohta

PSDA_sum_f1	PSDA_sum_f2	PSDA_sum_f3	CCA_f1	CCA_f2	CCA_f3
3.896971	4.119254	4.575920	0.3028430	0.2741514	0.2669149
4.474294	4.549097	4.406292	0.3335525	0.2597220	0.2564238
5.010334	4.474692	4.151357	0.3411201	0.2703358	0.2189455
4.915839	4.368423	4.323578	0.3289583	0.3110394	0.2421184
4.867986	4.590158	4.520489	0.3165068	0.3610076	0.2756416
4.702446	4.580038	4.602424	0.3026591	0.3378599	0.2960716

Näide juhuslikult genereeritud käskude järjendi kohta ehk millal kasutaja mingit käsku edastas

Start	Stop	Target
1	512	2
513	576	1
577	1312	3
1313	2048	1
2049	2688	2

¹<https://github.com/kahvel/MAPProject>

C R kood

Kogu kasutatud kood on kättesaadav koodirepositooriumist¹.

Aegridade faktoranalüüsi Ris

```
library(tsfa)
result_data <- read.csv("test5_results_2_all.csv", header=TRUE, sep=" ")
fit = estTSFmodel(ts(result_data), 3) # 3=faktorite arv
summary(fit)
```

Dünaamiline faktoranalüüs Ris 6 tunnuse ja 3 faktoriga

```
library(MARSS)
result_data <- read.csv("test5_results_2_all.csv", header=TRUE, sep=" ")
Z.vals = list(
  "z11", 0, 0,
  "z21", "z22", 0,
  "z31", "z32", "z33",
  "z41", "z42", "z43",
  "z51", "z52", "z53",
  "z61", "z62", "z63"
)
N.ts = 6
Z = matrix(Z.vals, nrow=N.ts, ncol=3, byrow=TRUE)
Q = B = diag(1,3)
R.vals = list(
  "r11",0,0,0,0,0,
  0,"r22",0,0,0,0,
  0,0,"r33",0,0,0,
  0,0,0,"r44",0,0,
  0,0,0,0,"r55",0,
  0,0,0,0,0,"r66")
R = matrix(R.vals, nrow=N.ts, ncol=N.ts, byrow=TRUE)
x0 = U = matrix(0, nrow=3, ncol=1)
A = matrix(0, nrow=6, ncol=1)
V0 = diag(5,3)
dfa.model = list(Z=Z, A="zero", R=R, B=B, U=U, Q=Q, x0=x0, V0=V0)
cntl.list = list(maxit=50)
tulemus = MARSS(t(as.matrix(result_data)), model=dfa.model, control=cntl.list)
```

¹<https://github.com/kahvel/MAProject>

D Faktorkaalud ja kommunaliteedid

Faktorkaalud ja kommunaliteedid peakomponentide (PK), peafaktorite (PF) ja iteratiivse peafaktorite (PFIT) jaoks

	PK1	PK2	PK3	h ²	PF1max	PF2max	PF3max	h ²	PF1smc	PF2smc	PF3smc	h ²
PSDA_sum_f1	0.684	0.375	-0.175	0.639	0.502	0.209	-0.108	0.307	0.537	0.236	-0.144	0.365
PSDA_sum_f2	0.774	-0.107	0.057	0.613	0.573	-0.091	0.021	0.337	0.600	-0.108	0.019	0.373
PSDA_sum_f3	0.631	0.352	0.397	0.680	0.463	0.196	0.196	0.291	0.503	0.224	0.255	0.369
CCA_f1	-0.079	0.716	-0.480	0.750	-0.045	0.376	-0.213	0.189	-0.047	0.431	-0.266	0.259
CCA_f2	0.456	-0.645	-0.123	0.639	0.302	-0.371	-0.066	0.234	0.322	-0.434	-0.094	0.301
CCA_f3	-0.190	0.238	0.826	0.775	-0.114	0.125	0.333	0.140	-0.115	0.134	0.392	0.185

	PFit1max	PFit2max	PFit3max	h ²	PFit1smc	PFit2smc	PFit3smc	h ²	TSFA1	TSFA2	TSFA3	h ²
PSDA_sum_f1	0.538	0.227	-0.165	0.368	0.538	0.227	-0.165	0.368	-0.112	0.024	-0.178	0.055
PSDA_sum_f2	0.611	-0.132	-0.058	0.394	0.611	-0.132	-0.058	0.394	1.028	0.166	-0.136	0.995
PSDA_sum_f3	0.599	0.222	0.347	0.528	0.598	0.222	0.347	0.528	0.230	-0.049	-1.022	0.995
CCA_f1	-0.054	0.580	-0.292	0.424	-0.054	0.580	-0.292	0.424	-0.060	0.985	-0.145	0.995
CCA_f2	0.310	-0.435	-0.198	0.324	0.310	-0.435	-0.198	0.324	0.093	-0.063	0.020	0.015
CCA_f3	-0.094	0.090	0.400	0.177	-0.094	0.090	0.400	0.177	-0.022	-0.079	-0.047	0.009